

Resumen 7 · Árboles de decisión

Ideas clave

- Preguntas $x_j \leq t \Rightarrow$ **cajas alineadas a los ejes**, una constante por hoja: mayoría (0/1), media (cuadrática), $\hat{p}$ (log-loss).
- **Impureza = costo de la mejor constante**: entropía (sorpresa promedio, bits), Gini (probabilidad de desacuerdo), error rate.
- Ganancia ponderada ≥ 0 por **concavidad**. El error rate es lineal a trozos $\Rightarrow$ puede dar ganancia 0 a un split útil: crecer con Gini/entropía.
- **CART** codicioso: $n - 1$ umbrales por feature (puntos medios), mejor split, recursión. Falla en XOR $\Rightarrow$ crecer y podar. Solo importa el orden (sin escalar).
- **Poda por costo-complejidad** $R(T) + \alpha|T|$, eslabón más débil, α por CV (regla de 1 SE).
- Interpretables pero de **alta varianza** (inestables); MDI sesgada; no extrapolan. Promediar árboles (bagging/random forest) baja la varianza.

Fórmulas

$$\text{Gini} = 1 - \sum_k \hat{p}_k^2, \quad H = - \sum_k \hat{p}_k \log_2 \hat{p}_k, \quad \text{máx. (K clases): } 1 - \frac{1}{K}, \log_2 K$$

$$\Delta I = I(m) - \frac{n_L}{n_m} I(L) - \frac{n_R}{n_m} I(R)$$

$$R_\alpha(T) = R(T) + \alpha|T|, \quad g(m) = \frac{R(m) - R(T_m)}{|T_m| - 1}$$

Ejemplo de 10 puntos: raíz $x_1 \leq 3.5$ ($\Delta I = 3/14$), ruta $\alpha = 2/15, 16/105, 3/14$

Trampas de examen

- Entropía = sorpresa; Gini = desacuerdo (no al revés).
- Basta evaluar $n - 1$ umbrales.
- La feature de la raíz no es necesariamente la más importante.
- Un árbol con defaults está sobreajustado.