

Resumen 0 · Fundamentos y matemáticas

Ideas clave

- ML aprende reglas a partir de datos: **datos + respuestas** → **modelo**, en vez de reglas escritas a mano.
- **Mitchell**: aprende de la experiencia E en la tarea T medida por P si P mejora con E . E = datos, P = desempeño (no el algoritmo ni el nº de parámetros).
- Paradigmas: **supervisado** (regresión: y continuo; clasificación: y discreto), **no supervisado** (clustering, reducción de dimensión), **refuerzo** (actuar y recibir recompensas).
- Meta: **generalizar**. Train ajusta, validación decide, test se usa **una vez**. Data leakage = el test influye en decisiones ⇒ nota optimista.
- Underfit = estudiante que siempre responde «C»; overfit = el que memorizó el examen pasado.
- Tres herramientas: álgebra lineal (modelo $\hat{y} = \mathbf{X}\mathbf{w}$), probabilidad (incertidumbre, Bayes), optimización (gradiente, convexidad).

Fórmulas

$$\hat{R}(h) = \frac{1}{n} \sum_i \ell(h(\mathbf{x}_i), y_i) \quad (\text{riesgo empírico, ERM})$$

$$\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta, \quad \|\mathbf{v}\|_2 = \sqrt{\sum v_j^2}, \quad \|\mathbf{v}\|_1 = \sum |v_j|$$

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)} \quad \text{posterior} \propto \text{likelihood} \times \text{prior}$$

$$w \leftarrow w - \eta \nabla J(w) \quad (\text{para } J = (w - 1)^2 \text{ converge si } 0 < \eta < 1)$$

Trampas de examen

- En clasificación y es discreto (si es continuo, es regresión).
- El clustering es no supervisado; la regresión es supervisada.
- Con una enfermedad rara, un positivo suele ser falsa alarma: $P(A | B) \neq P(B | A)$.
- Convexo ⇒ todo mínimo local es global.