

Resumen 1 · Regresión lineal

Ideas clave

- Modelo $\hat{y} = \mathbf{X}\mathbf{w}$; la columna de unos absorbe el sesgo. Residual $r_i = y_i - \hat{y}_i$.
- Costo $J = \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2$: **convexo** porque $\mathbf{v}^\top \mathbf{X}^\top \mathbf{X} \mathbf{v} = \|\mathbf{X}\mathbf{v}\|^2 \geq 0$.
- Dos rutas, misma respuesta: gradiente = 0 o **proyección ortogonal** de $\mathbf{y}$ sobre el espacio columna ($\mathbf{X}^\top \mathbf{r} = 0$).
- Cuadrados = **máxima verosimilitud con ruido gaussiano** (Laplace daría error absoluto).
- Descenso de gradiente cuando d o n son grandes o no hay forma cerrada. **Estandarizar** redondea el bowl. Batch / SGD / mini-batch.
- Polinomios: lineal en los **pesos**, curvo en x . Overfitting $\Rightarrow$ **pesos que explotan**.

Fórmulas

$$\begin{aligned}\mathbf{X}^\top \mathbf{X} \mathbf{w} &= \mathbf{X}^\top \mathbf{y} \Rightarrow \mathbf{w}^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \\ \nabla J &= 2\mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y}) = -2\mathbf{X}^\top \mathbf{r} \\ \mathbf{H} &= \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top, \quad \hat{\mathbf{y}} = \mathbf{H}\mathbf{y}, \quad \mathbf{H}^2 = \mathbf{H} \\ w_1 &= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad w_0 = \bar{y} - w_1 \bar{x} \\ \text{RMSE} &= \sqrt{\frac{1}{n} \sum r_i^2}, \quad \text{MAE} = \frac{1}{n} \sum |r_i|, \quad R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}\end{aligned}$$

Trampas de examen

- J es convexa.
- Con $\eta = 0$ no se aprende nada; el signo menos importa.
- R^2 puede ser negativo en validación.
- $\text{RMSE} \geq \text{MAE}$; la brecha delata outliers.
- Un peso es asociación, no causalidad; compara magnitudes solo con features estandarizadas.