

Resumen 2 · Regularización y selección de modelos

Ideas clave

- Train baja siempre con la complejidad; validación hace una U.
- **Sesgo** = error sistemático del ajuste promedio; **varianza** = cuánto cambia el ajuste entre training sets; σ^2 = ruido irreducible.
- Underfit: sesgo alto, varianza baja. Overfit: sesgo bajo, varianza alta.
- Regularizar = pérdida + $\lambda\Omega(\mathbf{w})$: cambia un poco de sesgo por mucha varianza. Estandarizar y **no penalizar el sesgo** b .
- **Ridge** encoge (nunca 0, siempre invertible); **lasso** pone pesos en 0 (rombo con esquinas, soft-threshold, descenso por coordenadas).
- **K-fold CV** para elegir λ / grado; regla de 1 SE; el test nunca participa; escalar dentro del pipeline.

Fórmulas

$$\mathbb{E}[(y - \hat{y})^2] = (\bar{f} - f)^2 + \mathbb{E}[(\hat{y} - \bar{f})^2] + \sigma^2$$

$$\mathbf{w}\lambda = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

$$\text{1-D: ridge } w = \frac{a}{1 + \lambda}; \quad \text{lasso } w = \text{sign}(a) \max(|a| - \frac{\lambda}{2}, 0)$$

$$\text{CV}(\lambda) = \frac{1}{K} \sum_{k=1}^K \text{Err}_k(\lambda)$$

Trampas de examen

- Varianza $\neq$ sesgo (el sesgo es el sistemático).
- Underfit = rígido, no flexible.
- Los folds de K-fold son de **validación**, no de test.
- Más datos bajan la varianza, no el sesgo.
- λ grande $\Rightarrow$ más simple.