

Resumen 0 · Fundamentos y matemáticas

Ideas clave

- ML aprende reglas a partir de datos: **datos + respuestas** → **modelo**, en vez de reglas escritas a mano.
- **Mitchell**: aprende de la experiencia E en la tarea T medida por P si P mejora con E . E = datos, P = desempeño (no el algoritmo ni el nº de parámetros).
- Paradigmas: **supervisado** (regresión: y continuo; clasificación: y discreto), **no supervisado** (clustering, reducción de dimensión), **refuerzo** (actuar y recibir recompensas).
- Meta: **generalizar**. Train ajusta, validación decide, test se usa **una vez**. Data leakage = el test influye en decisiones ⇒ nota optimista.
- Underfit = estudiante que siempre responde «C»; overfit = el que memorizó el examen pasado.
- Tres herramientas: álgebra lineal (modelo $\hat{\mathbf{y}} = \mathbf{X}\mathbf{w}$), probabilidad (incertidumbre, Bayes), optimización (gradiente, convexidad).

Fórmulas

$$\hat{R}(h) = \frac{1}{n} \sum_i \ell(h(\mathbf{x}_i), y_i) \quad (\text{riesgo empírico, ERM})$$

$$\mathbf{a}^\top \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta, \quad \|\mathbf{v}\|_2 = \sqrt{\sum v_j^2}, \quad \|\mathbf{v}\|_1 = \sum |v_j|$$

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)} \quad \text{posterior} \propto \text{likelihood} \times \text{prior}$$

$$w \leftarrow w - \eta \nabla J(w) \quad (\text{para } J = (w - 1)^2 \text{ converge si } 0 < \eta < 1)$$

Trampas de examen

- En clasificación y es discreto (si es continuo, es regresión).
- El clustering es no supervisado; la regresión es supervisada.
- Con una enfermedad rara, un positivo suele ser falsa alarma: $P(A | B) \neq P(B | A)$.
- Convexo ⇒ todo mínimo local es global.

Resumen 1 · Regresión lineal

Ideas clave

- Modelo $\hat{y} = \mathbf{X}\mathbf{w}$; la columna de unos absorbe el sesgo. Residual $r_i = y_i - \hat{y}_i$.
- Costo $J = \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2$: **convexo** porque $\mathbf{v}^\top \mathbf{X}^\top \mathbf{X} \mathbf{v} = \|\mathbf{X}\mathbf{v}\|^2 \geq 0$.
- Dos rutas, misma respuesta: gradiente = 0 o **proyección ortogonal** de $\mathbf{y}$ sobre el espacio columna ($\mathbf{X}^\top \mathbf{r} = 0$).
- Cuadrados = **máxima verosimilitud con ruido gaussiano** (Laplace daría error absoluto).
- Descenso de gradiente cuando d o n son grandes o no hay forma cerrada. **Estandarizar** redondea el bowl. Batch / SGD / mini-batch.
- Polinomios: lineal en los **pesos**, curvo en x . Overfitting $\Rightarrow$ **pesos que explotan**.

Fórmulas

$$\begin{aligned}\mathbf{X}^\top \mathbf{X} \mathbf{w} &= \mathbf{X}^\top \mathbf{y} \Rightarrow \mathbf{w}^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \\ \nabla J &= 2\mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y}) = -2\mathbf{X}^\top \mathbf{r} \\ \mathbf{H} &= \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top, \quad \hat{\mathbf{y}} = \mathbf{H}\mathbf{y}, \quad \mathbf{H}^2 = \mathbf{H} \\ w_1 &= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad w_0 = \bar{y} - w_1 \bar{x} \\ \text{RMSE} &= \sqrt{\frac{1}{n} \sum r_i^2}, \quad \text{MAE} = \frac{1}{n} \sum |r_i|, \quad R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}\end{aligned}$$

Trampas de examen

- J es convexa.
- Con $\eta = 0$ no se aprende nada; el signo menos importa.
- R^2 puede ser negativo en validación.
- $\text{RMSE} \geq \text{MAE}$; la brecha delata outliers.
- Un peso es asociación, no causalidad; compara magnitudes solo con features estandarizadas.

Resumen 2 · Regularización y selección de modelos

Ideas clave

- Train baja siempre con la complejidad; validación hace una U.
- **Sesgo** = error sistemático del ajuste promedio; **varianza** = cuánto cambia el ajuste entre training sets; σ^2 = ruido irreducible.
- Underfit: sesgo alto, varianza baja. Overfit: sesgo bajo, varianza alta.
- Regularizar = pérdida + $\lambda\Omega(\mathbf{w})$: cambia un poco de sesgo por mucha varianza. Estandarizar y **no penalizar el sesgo** b .
- **Ridge** encoge (nunca 0, siempre invertible); **lasso** pone pesos en 0 (rombo con esquinas, soft-threshold, descenso por coordenadas).
- **K-fold CV** para elegir λ / grado; regla de 1 SE; el test nunca participa; escalar dentro del pipeline.

Fórmulas

$$\mathbb{E}[(y - \hat{y})^2] = (\bar{f} - f)^2 + \mathbb{E}[(\hat{y} - \bar{f})^2] + \sigma^2$$

$$\mathbf{w}_\lambda = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

$$\text{1-D: ridge } w = \frac{a}{1 + \lambda}; \quad \text{lasso } w = \text{sign}(a) \max(|a| - \frac{\lambda}{2}, 0)$$

$$\text{CV}(\lambda) = \frac{1}{K} \sum_{k=1}^K \text{Err}_k(\lambda)$$

Trampas de examen

- Varianza $\neq$ sesgo (el sesgo es el sistemático).
- Underfit = rígido, no flexible.
- Los folds de K-fold son de **validación**, no de test.
- Más datos bajan la varianza, no el sesgo.
- λ grande $\Rightarrow$ más simple.

Resumen 3 · Clasificación logística y métricas

Ideas clave

- Una recta sobre 0/1 no es probabilidad (sale de $[0,1]$, un punto lejano la inclina).
- Log-odds lineal $\Rightarrow$ la probabilidad es **forzosamente** la sigmoide. Cada peso es un **odds ratio** e^{w_j} .
- Frontera $\mathbf{w}^\top \mathbf{x} + b = 0$: **clasificador lineal**. Umbral 0.5 $\Leftrightarrow z \geq 0$; el umbral es movible según costos.
- Se entrena con **cross-entropy** (MLE Bernoulli, convexa); el error² sobre σ es no convexo y se estanca. Sin forma cerrada $\Rightarrow$ gradiente.
- Clases separables sin regularizar $\Rightarrow \|\mathbf{w}\| \rightarrow \infty$: agregar $\lambda \|\mathbf{w}\|^2$.
- Accuracy **miente** con desbalance: usar matriz de confusión, precision, recall, F1, ROC/AUC. Bajar el umbral $\Rightarrow$ recall $\uparrow$, precision $\downarrow$.

Fórmulas

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \sigma(0) = \frac{1}{2}, \quad \sigma(-z) = 1 - \sigma(z), \quad \sigma' = \sigma(1 - \sigma)$$

$$J = -\frac{1}{n} \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)], \quad \nabla_{\mathbf{w}} J = \frac{1}{n} \mathbf{X}^\top (\mathbf{p} - \mathbf{y})$$

$$\text{prec} = \frac{TP}{TP + FP}, \quad \text{rec} = \frac{TP}{TP + FN}, \quad F1 = \frac{2PR}{P + R}, \quad \text{acc} = \frac{TP + TN}{\text{total}}$$

$$p_k = \frac{e^{z_k}}{\sum_j e^{z_j}} \quad (\text{softmax}; K = 2 \Rightarrow \sigma(z_1 - z_0)), \quad \partial \ell / \partial z_k = p_k - y_k$$

Trampas de examen

- Accuracy = correctas / total (no incorrectas).
- FN = positivo real declarado negativo.
- F1 = media **armónica** de precision y recall (queda cerca del menor).
- El umbral 0.5 no exige clases balanceadas.
- AUC 0.5 = azar.

Resumen 4 · Modelos generativos: Bayes, Naive Bayes, LDA y QDA

Ideas clave

- **Generativo:** modela $p(\mathbf{x} | y)$ y $P(y)$, luego Bayes. **Discriminativo:** $P(y | \mathbf{x})$ directo.
- Regla **MAP:** $\hat{y} = \arg \max_k \pi_k p(\mathbf{x} | y = k)$; la evidencia $p(\mathbf{x})$ no cambia al ganador. MAP = MLE + prior.
- MLE = **contar y promediar:** $\pi_k = N_k / N$, medias, varianzas, covarianzas.
- **Naive Bayes:** independencia condicional; d parámetros en vez de 2^d ; decidir con logs; Laplace evita ceros (MAP); probabilidades sobreconfiadas.
- **LDA:** Σ compartida $\Rightarrow$ el término cuadrático se cancela $\Rightarrow$ frontera **lineal**, posterior $\sigma(\mathbf{w}^\top \mathbf{x} + b)$.
QDA: Σ_k propias $\Rightarrow$ **cuadrática**, más parámetros.
- Pocos datos $\Rightarrow$ generativo aprende más rápido; muchos datos o supuestos falsos $\Rightarrow$ discriminativo (Ng y Jordan).

Fórmulas

$$P(y = k | \mathbf{x}) = \frac{\pi_k p(\mathbf{x} | y = k)}{\sum_j \pi_j p(\mathbf{x} | y = j)}$$

$$p(w | y = k) = \frac{\text{count}(w, k) + \alpha}{\text{total}(k) + \alpha V}$$

$$D^Z = (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}), \quad \delta_k = \log \pi_k - \frac{1}{2} D_k^Z - \frac{1}{2} \log |\Sigma_k|$$

$$\text{LDA: } \mathbf{w} = \Sigma^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0), \quad \text{1-D: } x^* = \frac{\mu_0 + \mu_1}{2} - \frac{\sigma^2}{\mu_1 - \mu_0} \log \frac{\pi_1}{\pi_0}$$

Trampas de examen

- $\pi_k = N_k / N$, no N_k / K .
- LDA = Σ **compartida**; QDA = Σ **propia**.
- Gaussian NB: $2Kd$ números (+ priors).
- Prior raro $\Rightarrow$ la frontera se corre hacia la clase rara.

Resumen 5 · Support Vector Machines

Ideas clave

- Entre infinitas rectas separadoras, el SVM elige la de **margen máximo**. Etiquetas $y \in \{-1, +1\}$: $y_i f(\mathbf{x}_i) > 0 \Leftrightarrow$ correcto.
- $\mathbf{w} \perp$ frontera. Margen funcional cambia con la escala; el **geométrico** no. Normalización canónica: $\min_i y_i f(\mathbf{x}_i) = 1 \Rightarrow$ banda $2/\|\mathbf{w}\|$.
- Primal: QP convexo. Restricciones **activas** = vectores de soporte; solo ellos definen la frontera.
- Lagrange: α_i = precio/fuerza de cada restricción. **KKT** + holgura complementaria. Dual: solo productos $\mathbf{x}_i^\top \mathbf{x}_j \Rightarrow$ kernels.
- Margen suave: holguras ξ_i y precio **C** (C grande = menos regularización, $\lambda \propto 1/C$). Dual: $0 \leq \alpha_i \leq C$. Equivale a **hinge + L2**.
- Práctica: **estandarizar**, empezar lineal, RBF con C y γ por CV. No da probabilidades (Platt), es binario (OvR/OvO), $O(n^2)$ – $O(n^3)$.

Fórmulas

$$r = \frac{\mathbf{w}^\top \mathbf{x} + b}{\|\mathbf{w}\|}, \quad \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \text{ s.a. } y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1$$

$$\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i, \quad \sum_i \alpha_i y_i = 0, \quad \alpha_i [y_i f(\mathbf{x}_i) - 1] = 0$$

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j, \quad b = y_k - \mathbf{w}^\top \mathbf{x}_k$$

$$\min \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_i \max(0, 1 - y_i f(\mathbf{x}_i))$$

Trampas de examen

- Estandarizar **no** es opcional.
- El SVM es discriminativo, no da $P(y | \mathbf{x})$.
- b se recupera con un vector de soporte, no se fija en 0.
- El $\frac{1}{2}$ en $\frac{1}{2}\|\mathbf{w}\|^2$ solo cancela el 2 al derivar.
- Más vectores de soporte $\neq$ mejor ajuste.

Resumen 6 • Kernels

Ideas clave

- Una frontera curva es una frontera **plana** en un espacio de features ϕ adecuado (anillos $\rightarrow x_1^2 + x_2^2$).
- **Truco**: el dual solo usa $\mathbf{x}_i^\top \mathbf{x}_j$; cámbialo por $K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$ **sin construir** ϕ .
- Kernel válido $\Leftrightarrow$ **simétrico y PSD** (Mercer): Gram con autovalores ≥ 0 . Cerrados bajo +, $\times$, escala positiva.
- Lineal (global), polinómico (todos los monomios hasta grado d , global), **RBF** (local, ϕ de dimensión infinita).
- γ del RBF: pequeño $\Rightarrow$ casi lineal (underfit); grande $\Rightarrow$ islas (overfit). C y γ juntos por CV; estandarizar.
- **Representante**: $f = \sum_i \alpha_i K(\mathbf{x}_i, \cdot)$. **Kernel ridge** en forma cerrada. Costo $O(n^2)$ memoria, $O(n^3)$ tiempo.

Fórmulas

$$\begin{aligned}(\mathbf{x}^\top \mathbf{z})^2 &= \phi(\mathbf{x})^\top \phi(\mathbf{z}), \quad \phi(\mathbf{x}) = (x_1^2, \sqrt{2}x_1x_2, x_2^2) \\ K_{\text{poly}} &= (c + \mathbf{x}^\top \mathbf{x}')^d, \quad K_{\text{RBF}} = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2) \\ e^{2\gamma \mathbf{x}^\top \mathbf{x}'} &= \sum_{k=0}^{\infty} \frac{(2\gamma)^k}{k!} (\mathbf{x}^\top \mathbf{x}')^k \quad (\text{todos los grados} \Rightarrow \phi \text{ infinita}) \\ \boldsymbol{\alpha} &= (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}, \quad f(\mathbf{x}) = \sum_i \alpha_i K(\mathbf{x}_i, \mathbf{x})\end{aligned}$$

Trampas de examen

- El truco **no** construye ϕ .
- El RBF tiene ϕ infinita que nunca se calcula.
- Restar kernels puede romper la PSD.
- Nunca elegir γ por accuracy de entrenamiento.

Resumen 7 · Árboles de decisión

Ideas clave

- Preguntas $x_j \leq t \Rightarrow$ **cajas alineadas a los ejes**, una constante por hoja: mayoría (0/1), media (cuadrática), $\hat{p}$ (log-loss).
- **Impureza = costo de la mejor constante**: entropía (sorpresa promedio, bits), Gini (probabilidad de desacuerdo), error rate.
- Ganancia ponderada ≥ 0 por **concavidad**. El error rate es lineal a trozos $\Rightarrow$ puede dar ganancia 0 a un split útil: crecer con Gini/entropía.
- **CART** codicioso: $n - 1$ umbrales por feature (puntos medios), mejor split, recursión. Falla en XOR $\Rightarrow$ crecer y podar. Solo importa el orden (sin escalar).
- **Poda por costo-complejidad** $R(T) + \alpha|T|$, eslabón más débil, α por CV (regla de 1 SE).
- Interpretables pero de **alta varianza** (inestables); MDI sesgada; no extrapolan. Promediar árboles (bagging/random forest) baja la varianza.

Fórmulas

$$\text{Gini} = 1 - \sum_k \hat{p}_k^2, \quad H = - \sum_k \hat{p}_k \log_2 \hat{p}_k, \quad \text{máx. (K clases): } 1 - \frac{1}{K}, \log_2 K$$

$$\Delta I = I(m) - \frac{n_L}{n_m} I(L) - \frac{n_R}{n_m} I(R)$$

$$R_\alpha(T) = R(T) + \alpha|T|, \quad g(m) = \frac{R(m) - R(T_m)}{|T_m| - 1}$$

Ejemplo de 10 puntos: raíz $x_1 \leq 3.5$ ($\Delta I = 3/14$), ruta $\alpha = 2/15, 16/105, 3/14$

Trampas de examen

- Entropía = sorpresa; Gini = desacuerdo (no al revés).
- Basta evaluar $n - 1$ umbrales.
- La feature de la raíz no es necesariamente la más importante.
- Un árbol con defaults está sobreajustado.